



AI VIET NAM
@aivietnam.edu.vn

AI VIET NAM – AI Conquer 2026 – Module 03

Dự Báo Phụ Tải Điện Theo Giờ Dựa Trên Mô Hình Xếp Chồng Thích Ứng Ngữ Cảnh Và Kỹ Thuật Đặc Trưng Vật Lý

Debug Team

Nguyễn Thị Diễm My Lê Tiến Anh Nguyễn Mạnh Tân

Hoàng Nguyễn Nhật Minh Lê Minh Hoàng

I. Tóm tắt nghiên cứu

Mục lục

II. Giới thiệu và câu hỏi nghiên cứu

III. Tổng quan các nghiên cứu liên quan

Tiến trình phát triển các phương pháp dự báo phụ tải

Các phương pháp dự báo phụ tải điện ngắn hạn (*Short-Term Load Forecasting* – STLF) trong có thể phân chia thành ba giai đoạn phát triển chính.

Mô hình chuỗi thời gian thống kê: Các phương pháp cổ điển như ARIMA, SARIMAX và Holt-Winters Exponential Smoothing [hyndman2018forecasting](#) cung cấp nền tảng toán học tường minh với chi phí tính toán thấp. Tuy nhiên, chúng dựa trên giả định về tính dừng (*stationarity*) và quan hệ tuyến tính, khiến các mô hình này khó nắm bắt biến động thời tiết cực đoan và phản ứng phi tuyến của phụ tải điện.

Học máy dạng bảng (*Tabular ML*): Các thuật toán Gradient Boosted Decision Trees (GBDT) như XGBoost [chen2016xgboost](#) và LightGBM [ke2017lightgbm](#) đã trở thành giải pháp ưu việt cho các bài toán chuỗi thời gian phức tạp. Cấu trúc phân nhánh của cây cho phép xấp xỉ các quan hệ phi tuyến, xử lý tốt đặc trưng đa thang đo (multi-scale features) và kiểm soát quá khớp qua các cơ chế điều chuẩn (regularization) hiệu quả [hong2016probabilistic](#).

Mô hình học sâu (*Deep Learning*): Sự phát triển của mạng hồi quy (RNN, LSTM), mạng tích chập thời gian (TCN) và các biến thể Transformer chuỗi thời gian (Informer [zhou2021informer](#), Autoformer [wu2021autoformer](#), PatchTST [nie2023time](#)) mở ra khả năng mô hình hóa phụ thuộc dài hạn qua cơ chế tự chú ý (self-attention). Tuy nhiên, các nghiên cứu thực nghiệm quy mô lớn [makridakis2018statistical](#) chỉ ra rằng trên dữ liệu chuỗi thời gian thực tế, mạng học sâu phức tạp không phải lúc nào cũng vượt trội hơn các thuật Học máy dạng bảng. Hơn nữa, khi chu kỳ dự báo kéo dài mà không có phản hồi nhân (ground-truth feedback), cơ chế tự hồi quy (Autoregressive mechanism) dễ dẫn đến hiện tượng tích lũy sai số (*error accumulation*) [lai2018modeling](#).

Nghiên cứu của Roy và cộng sự (2025)

Trong khuôn khổ cuộc thi *IISE PG&E Energy Analytics Challenge 2025* [pge2025zenodo](#), Roy, Pyltsov và Hu [roy2025hourly](#) đã cung cấp một minh chứng thực nghiệm điển hình về ưu thế của Học máy dạng bảng trước các kiến trúc Transformer sâu.

Đặc trưng cốt lõi của bài toán PG&E là bối cảnh ràng buộc: dự báo phụ tải trọn vẹn một năm mà không có giá trị phụ tải thực tế theo thời gian thực (không có nhãn phản hồi). Để giải quyết bài toán này, Roy và cộng sự [roy2025hourly](#) đề xuất chiến lược gồm: (i) Khử đa cộng tuyến giữa các trạm quan trắc bằng Phân tích Thành phần Chính (PCA); (ii) Chia chu kỳ ngày đêm thành 24 bài toán con theo giờ (*24-Hourly Binning*) và huấn luyện 24 mô hình XGBoost độc lập tương ứng; và (iii) Bổ sung đặc trưng *PCA Lag1* nhằm phản ánh quán tính nhiệt của môi trường. Kết quả thực nghiệm khẳng định hướng tiếp cận sử dụng XGBoost đạt độ chính xác vượt trội so với các mô hình học sâu.

Khoảng trống nghiên cứu và Đề xuất đóng góp

Mặc dù baseline của Roy và cộng sự **roy2025hourly** đạt hiệu năng ấn tượng, việc phân tích sâu cho thấy các khoảng trống nghiên cứu cần được giải quyết: (i) Chưa có các đặc trưng về vật lý nhiệt công trình; (ii) mã hóa thời gian một cách rời rạc có thể gây gián đoạn chu kỳ thời gian; (iii) chỉ sử dụng một họ mô hình đơn nhất chưa khai thác được tính bổ trợ giữa các thuật toán, mô hình khác nhau.

Dựa trên các cơ sở đó, nghiên cứu này đề xuất các hướng mở rộng như sau:

1. **Bổ sung tri thức vật lý nhiệt công trình:** Theo tiêu chuẩn ASHRAE **ashrae2021fundamentals**, nhu cầu điện năng cho sưởi ấm và làm mát (*HVAC*) có mối quan hệ với nhiệt độ ngoài trời. Lấy mốc 18°C làm cơ sở, ta tính được hai chỉ số nhiệt động lực học là *Cooling Degree Days* (CDD) và *Heating Degree Days* (HDD). Đồng thời, thay vì mã hóa thời gian một cách rời rạc, chúng tôi sử dụng các hàm điều hòa Fourier liên tục **cleveland1990stl**, **hyndman2018forecasting**.
2. **Khai thác tính bù trừ giữa các họ mô hình:** Mô hình ElasticNet **zou2005regularization** vốn ổn định ở khoảng phụ tải thấp và mô hình XGBoost **chen2016xgboost** nhạy cảm ở các mức phụ tải cao. Việc sử dụng kiến trúc *Context-Aware Stacking* (CAS), với meta-learner (LightGBM **ke2017lightgbm**) nhận đồng thời dự báo từ hai mô hình cơ sở (ElasticNet và XGBoost) cùng với các đặc trưng kể trên; cho phép meta-learner tự động điều chỉnh tỷ trọng giữa hai mô hình đó dựa trên điều kiện vận hành cụ thể, từ đó tối ưu điểm mạnh của từng mô hình.

Bên cạnh đó, để nâng cao độ tin cậy, nhóm nghiên cứu áp dụng phương pháp SHAP **lundberg2017shap** để bóc tách đóng góp của các đặc trưng ngoại sinh theo từng khung giờ trong ngày. Đồng thời, do các khoảng tin cậy dựa trên giả định phân phối chuẩn thường không phù hợp với dữ liệu phụ tải có tính dị phương sai và phân phối đuôi dày, chúng tôi ứng dụng lý thuyết *Conformal Prediction* (CP) **vovk2005algorithmic** nhằm cung cấp các khoảng dự báo có bảo đảm bao phủ toán học không phụ thuộc phân phối (*distribution-free validity*), hỗ trợ việc ra quyết định điều độ an toàn hơn.

IV. Phương pháp và kiến trúc nghiên cứu

V. Dữ liệu và thiết kế thí nghiệm

VI. Kết quả và thảo luận

Phần này tổng hợp toàn bộ kết quả thực nghiệm trên tập dữ liệu kiểm thử Năm 3 (năm 2022, gồm 8.760 giờ) của lưới điện PG&E, đồng thời phân tích cơ chế hoạt động và nguyên nhân tạo nên sự cải thiện của mô hình đề xuất. Mọi so sánh đều được thực hiện trên cùng một tập dữ liệu và tuân thủ đúng quy trình đánh giá chuẩn từ bài báo gốc [iise2025pge](#) nhằm đảm bảo tính khách quan và công bằng.

Trình bày kết quả

1. Đánh giá hiệu năng tổng thể của mô hình đề xuất

Trước hết, nhằm đánh giá liệu mô hình kết hợp đề xuất có thực sự vượt trội hơn bài báo gốc và các mô hình đơn lẻ hay không, Bảng ?? so sánh độ chính xác dự báo của mô hình **Context-Aware Stacking (CAS)** với mô hình cơ sở của bài báo gốc (*Paper Baseline*) cùng các cấu hình đơn lẻ. Hiệu năng được đo lường qua bốn chỉ số phổ biến trong các cuộc thi dự báo năng lượng tiêu chuẩn quốc tế như GEFCom [hong2014global](#): sai số toàn phương trung bình (RMSE, đơn vị MW), sai số tuyệt đối trung bình (MAE, đơn vị MW), sai số phần trăm tuyệt đối trung bình (MAPE, tính theo %) và hệ số xác định (R^2).

Bảng 1: So sánh hiệu năng dự báo phụ tải trên tập kiểm thử Năm 3 (2022)


Cấu hình mô hình	Kiến trúc / Đặc trưng	Số biến	RMSE (MW) ↓	MAE (MW) ↓	MAPE (%) ↓	R^2 ↑
Paper Baseline iise2025pge	24 mô hình XGBoost theo giờ (gốc)	18	170.84	120.77	5.38%	0.8746
Feature-Enhanced	24 mô hình XGBoost (+Fourier, CDD/HDD quayle1980heating)	24	160.80	114.74	5.14%	0.8889
Standalone ElasticNet	Hồi quy tuyến tính toàn cục zou2005regularization	24	207.46	156.32	6.92%	0.8150
Standalone XGBoost	Cây quyết định toàn cục chen2016xgboost	25	165.85	119.40	5.45%	0.8818
Proposed CAS (Đề xuất)	Mô hình Stacking wolpert1992stacked kết hợp (Meta: LightGBM ke2017lightgbm)	24	141.81	106.98	4.75%	0.9136

Từ số liệu ở Bảng ??, chúng ta rút ra ba nhận định quan trọng:

- *Đặc trưng thời tiết bổ sung mang lại hiệu quả rõ rệt:* Khi bổ sung sóng điều hòa Fourier cùng các chỉ số nhu cầu làm mát và sưởi ấm (CDD và HDD), mô hình 24-XGBoost giảm được 10.04 MW sai số RMSE (tương đương giảm 5.88%). Điều này chứng minh rằng việc mô hình hóa chu kỳ mùa liên tục và ngưỡng nhiệt bật điều hòa đã cung cấp thêm thông tin rất giá trị cho mô hình cây.
- *Mô hình tuyến tính đơn lẻ bộc lộ giới hạn rõ rệt:* Mô hình ElasticNet toàn cục (*Standalone ElasticNet*) có sai số khá lớn (207.46 MW), cho thấy quan hệ giữa thời tiết và phụ tải có tính phi tuyến rất mạnh nên một phương trình tuyến tính đơn thuần không thể bao quát toàn bộ các khung giờ. Trong khi đó, mô hình cây toàn cục (*Standalone XGBoost*) đạt kết quả khả quan hơn nhiều (165.85 MW), vượt qua cả mô hình baseline 24-Hourly XGBoost của bài báo gốc.
- *Mô hình đề xuất CAS dẫn đầu toàn diện:* Mô hình CAS đạt kết quả tốt nhất trên cả bốn thước đo với RMSE hạ xuống **141.81 MW**, MAE còn **106.98 MW**, MAPE chỉ còn **4.75%** và hệ số R^2 đạt **0.9136**. So với mô hình chuẩn của bài báo gốc, CAS giúp cắt giảm tới **29.03 MW** sai số (cải thiện **17.00%**). Trong thực tế điều độ hệ thống điện, mức giảm sai số 17% này giúp tiết kiệm hàng triệu USD chi phí dự phòng công suất phát mỗi năm.

Hình ?? đối chiếu phụ tải thực tế (*Actual Load*) và dự báo của mô hình đề xuất CAS (*Predicted Load*) trên tập kiểm thử Năm 3 (năm 2022) theo hai góc nhìn:

- *Toàn cảnh 8.760 giờ cả năm (Khung a):* Đánh giá tính ổn định dài hạn của mô hình. Đường dự báo bám sát chu kỳ mùa của lưới điện PG&E—từ vùng phụ tải nền ôn hòa (1.800–2.500 MW) vào mùa xuân/thu đến các đợt cao điểm (3.500–4.000 MW) vào mùa hè. Sự trùng khớp liên tục này khẳng định mô hình duy trì độ khái quát hóa tốt, không bị trôi dạt sai số (*seasonal drift*) hay thiên lệch hệ thống qua các quý trong năm.
- *Phóng to 336 giờ đợt sóng nhiệt lịch sử 01/09 – 14/09/2022 (Khung b):* Đóng vai trò bài kiểm thử áp lực cực hạn (*stress-test*), đồng thời khắc phục hiện tượng nén dữ liệu ở chuỗi thời gian dài. Góc nhìn cận cảnh minh chứng CAS vận hành nhịp nhàng theo cơ chế hai trạng thái (*Dual-Regime*):
 - *Ban đêm (00:00 – 06:00):* Đường dự báo làm mịn tốt quanh mức sàn 2.500 MW, loại bỏ hoàn toàn dao động răng cưa nhân tạo nhờ ưu thế của mô hình tuyến tính ElasticNet.
 - *Cao điểm chiều tối (16:00 – 20:00):* Bám sát độ dốc và biên độ cực đại vượt ngưỡng 4.500 MW nhờ khả năng mô hình hóa phi tuyến của XGBoost.
 - *Dải tô bóng phần dư màu đỏ cho thấy ngay cả tại đỉnh nhiệt kỷ lục ngày 06/09/2022, mô hình chỉ lệch nhẹ và tuyệt đối không bị trễ pha (*lag*).*



Hình 1: Đối chiếu giữa phụ tải thực tế (Actual Load) và dự báo của mô hình đề xuất CAS (Predicted Load) trên tập kiểm thử Năm 3 (năm 2022): (a) Đánh giá xu hướng tổng thể và tính ổn định dài hạn qua 8.760 giờ cả năm; (b) Phóng to chi tiết 2 tuần cao điểm sóng nhiệt mùa hè (01/09/2022 – 14/09/2022) đóng vai trò kiểm thử áp lực cực hạn và kiểm chứng khả năng bám sát chu kỳ ngày/đêm.

2. Phân tích mức độ đóng góp của từng thành phần cải tiến

Để xác định rõ mức độ đóng góp của từng nhóm đặc trưng thời tiết cũng như hiệu quả của cơ chế kết hợp mô hình, chúng tôi tiến hành thử nghiệm bóc tách từng phần. Kết quả kiểm định chéo trên tập huấn luyện (CV RMSE) và kiểm thử thực tế trên Năm 3 (Test RMSE) được trình bày trong Bảng ??.

Bảng 2: Kết quả phân tích đóng góp của từng thành phần cải tiến

Cấu hình thử nghiệm	Số biến	CV RMSE (MW)	Test RMSE (MW)	Mức giảm sai số (MW)
(1) Mô hình gốc (PCA + biến trễ Lag 1)	18	256.01	170.84	–
(2) (1) + Bổ sung 4 biến sóng Fourier	22	251.52	161.22	–9.62
(3) (2) + Bổ sung 2 biến nhu cầu nhiệt CDD / HDD quayle1980heating	24	251.47	160.80	–0.42
(4) (3) + Cơ chế Stacking phối hợp (CAS) wolpert1992stacked	24	–	141.81	–18.99

Bảng ?? cho thấy lộ trình cải thiện độ chính xác diễn ra rất rõ ràng:

- *Đóng góp của 4 biến sóng điều hòa Fourier*: Nhóm đặc trưng này mang lại mức giảm sai số đáng kể nhất ở khâu dữ liệu (9.62 MW RMSE trên tập kiểm thử). 4 biến này bao gồm 2 biến chu kỳ ngày (Sin_Hour, Cos_Hour) và 2 biến chu kỳ năm (Sin_Year, Cos_Year). Nhờ tính chất liên tục của các hàm lượng giác sin và cos, mô hình nắm bắt được sự biến thiên tuần hoàn theo giờ và sự chuyển dịch mượt mà qua các mùa, khắc phục triệt để hiện tượng nhảy bậc nhân tạo khi chỉ dùng biến phân loại tháng rời rạc.
- *Đóng góp của các chỉ số nhu cầu nhiệt CDD và HDD **quayle1980heating***: Việc bổ sung 2 biến nhiệt độ chênh lệch giúp giảm thêm 0.42 MW sai số, hỗ trợ mô hình nhận biết nhanh thời điểm xuất hiện nhu cầu sưởi ấm hoặc làm mát khi nhiệt độ môi trường dịch chuyển khỏi ngưỡng dễ chịu 18°C.
- *Đóng góp then chốt từ cơ chế học kết hợp CAS **wolpert1992stacked***: Bước cải tiến quan trọng nhất giúp hạ sâu sai số thêm 18.99 MW RMSE (đưa sai số về mức 141.81 MW) đến từ cấu trúc Stacking. Điều này chứng minh việc phối hợp giữa mô hình tuyến tính và mô hình cây mang lại giá trị vượt trội so với việc chỉ bổ sung đặc trưng cho một mô hình đơn lẻ.


3. Phân tích hai chế độ vận hành (Dual-Regime) và tính bổ trợ mô hình

Một mô hình kết hợp (Stacking **wolpert1992stacked**) chỉ thực sự phát huy hiệu quả khi các mô hình thành phần không cùng mắc một lỗi giống nhau trên cùng một mẫu dữ liệu. Chúng tôi tính hệ số tương quan phần dư giữa ElasticNet **zou2005regularization** và XGBoost **chen2016xgboost**:

$$r_{\text{residual}} = 0.6131$$

Hệ số tương quan 0.6131 (Hình ??) là một con số rất thuận lợi: nó vừa đủ để chứng minh hai mô hình dự báo cùng xu hướng, nhưng cũng đủ độc lập để bổ trợ cho nhau ở những trường hợp khó.

Figure 9: Pairwise Residual Correlation Matrix (Base Learners)




Hình 2: Ma trận tương quan sai số phần dư giữa mô hình tuyến tính (ElasticNet) và mô hình cây (XGBoost).

Để làm rõ hơn nhận định này, chúng tôi chia tập kiểm thử thành các điều kiện vận hành thực tế như giờ đêm, sóng nhiệt, giờ cao điểm, ngày thường và cuối tuần. Sai số của từng mô hình được tổng hợp trong Bảng ?? và minh họa trực quan ở Hình ??.

Bảng 3: Sai số RMSE (MW) của các mô hình trong các điều kiện vận hành khác nhau

Điều kiện vận hành	Số mẫu	ElasticNet (MW)	XGBoost (MW)	Mô hình tốt hơn	CAS (MW)	Mức cải thiện của CAS
Ban đêm tải thấp (00:00 - 06:00)	2.190	131.33	141.37	ElasticNet	100.50	+30.83 MW
Sóng nhiệt mùa hè (CDD > 3°C)	2.196	313.27	244.16	XGBoost	215.44	+28.72 MW
Mùa đông cần sưởi (HDD > 5°C)	1.798	131.74	100.14	XGBoost	93.25	+6.90 MW
Thời tiết ôn hòa (HDD, CDD ≤ 1°C)	1.236	187.75	145.46	XGBoost	138.51	+6.96 MW
Giờ cao điểm chiều tối (15:00 - 19:00)	1.825	243.48	171.72	XGBoost	163.45	+8.27 MW
Giờ nắng trưa (10:00 - 14:00)	1.825	266.69	205.26	XGBoost	199.17	+6.09 MW
Ngày làm việc (Thứ 2 - Thứ 6)	6.240	207.53	164.44	XGBoost	147.49	+16.94 MW
Ngày cuối tuần và ngày nghỉ lễ	2.760	215.04	176.16	XGBoost	158.49	+17.67 MW




Hình 3: So sánh sai số RMSE giữa ElasticNet, XGBoost và mô hình kết hợp CAS theo từng điều kiện cụ thể.

Số liệu từ Bảng ?? đã chỉ ra hai phát hiện rất thú vị:

- **Vào ban đêm (00:00 - 06:00):** Mô hình tuyến tính ElasticNet hoạt động tốt hơn hẳn XGBoost (131.33 MW so với 141.37 MW). Lý do là ban đêm người dân đi ngủ, phụ tải duy trì ở mức sàn ổn định và biến thiên tương đối phẳng. Mô hình cây với cơ chế phân chia ngưỡng bậc thang dễ tạo ra các đường xấp xỉ răng cưa và bị nhiễu; trong khi đó, hàm tuyến tính trơn tru của ElasticNet lại khớp hoàn hảo với trạng thái này.
- **Khi có sóng nhiệt ($CDD > 3^{\circ}\text{C}$):** Tình thế đảo ngược hoàn toàn. Khi nhiệt độ tăng cao, điều hòa nhiệt độ bật đồng loạt khiến phụ tải vọt lên phi tuyến tính. ElasticNet bị hụt hơi với sai số vọt lên 313.27 MW, trong khi XGBoost xử lý tốt các ngưỡng phi tuyến này với RMSE chỉ 244.16 MW (vượt trội hơn tới 69.11 MW).
- **Vai trò điều phối của Meta-Learner:** Điều ấn tượng nhất là ở bất kỳ tình huống nào, mô hình kết hợp CAS cũng cho ra kết quả tốt hơn mô hình thành phần tốt nhất. Chẳng hạn vào ban đêm, CAS đạt RMSE 100.50 MW (tốt hơn ElasticNet tới 30.83 MW), và khi có sóng nhiệt, CAS tiếp tục giảm thêm 28.72 MW so với XGBoost.

4. Phân tích mức độ ảnh hưởng của các biến theo từng khung giờ qua SHAP

Để kiểm tra xem mô hình có thực sự hiểu quy luật thực tế và phân bổ trọng số hợp lý theo thời gian hay không, nghiên cứu sử dụng phương pháp SHAP [lundberg2017unified](#) để đo mức độ ảnh hưởng của từng biến đầu vào theo 24 giờ trong ngày (Hình ??).



Hình 4: Biểu đồ nhiệt thể hiện mức độ quan trọng (giá trị $|\text{SHAP}|$) của các biến đầu vào theo 24 giờ trong ngày.

Kết quả giải thích SHAP hoàn toàn trùng khớp với trực giác thực tế:

- Vào khung giờ trưa và chiều (12:00 - 18:00), các yếu tố liên quan đến nhiệt độ và nắng như chỉ số nhu cầu làm mát (CDD), bức xạ mặt trời (GHI) và thành phần nhiệt độ chính (PCA_Temp_1) có giá trị SHAP cao nhất, quyết định phần lớn mức tiêu thụ điện.
- Vào khung giờ đêm (00:00 - 06:00), ảnh hưởng của nhiệt độ giảm xuống rất thấp. Lúc này, mô hình phụ thuộc chủ yếu vào mức phụ tải của ngày hôm trước (Lag 1) và chu kỳ mùa Fourier. Mô hình tổng hợp (Meta-Learner) nắm bắt được điều này và tự động ưu tiên kết quả từ mô hình tuyến tính ElasticNet.

Thảo luận

Dựa trên các bằng chứng thực nghiệm ở trên, chúng tôi phân tích sâu hơn về các câu hỏi cốt lõi của đề tài:

1. Kết quả thực nghiệm cho thấy điều gì? Kết quả cho thấy nhu cầu tiêu thụ điện trong thực tế không bao giờ đi theo một quy luật cố định. Nó phân tách thành hai trạng thái rất rõ rệt: phụ tải nền ban đêm diễn biến phẳng và tuyến tính, còn phụ tải ban ngày lại phụ thuộc mạnh vào nhiệt độ và mang tính phi tuyến. Do đó, việc chỉ dùng duy nhất một mô hình cây cho mọi thời điểm sẽ dẫn đến việc mô hình bị gượng ép: vừa dễ bị nhiễu ở vùng tải phẳng ban đêm, vừa chưa khai thác hết độ mượt mà của dữ liệu.

2. Kết quả có giải quyết trọn vẹn các mục tiêu nghiên cứu đặt ra không? Các số liệu thực nghiệm đã làm sáng tỏ đầy đủ ba vấn đề trọng tâm của nghiên cứu:

- Về hiệu năng dự báo tổng thể:* Mô hình đề xuất CAS đã chứng minh ưu thế vượt trội trên

tập kiểm thử độc lập Năm 3, giúp cắt giảm 17,00% sai số RMSE (từ 170,84 MW của bài báo gốc xuống còn 141,81 MW).

- *Về vai trò của đặc trưng thời tiết và tính bù trừ sai số:* Việc bổ sung chu kỳ mùa Fourier và các chỉ số nhu cầu nhiệt CDD/HDD giúp giảm trực tiếp 10,04 MW sai số. Đồng thời, kết quả phân tích theo điều kiện đã khẳng định sự bù trừ rõ nét giữa hai họ mô hình: ElasticNet chiếm ưu thế ban đêm, trong khi XGBoost vượt trội khi có sóng nhiệt, với hệ số tương quan phần dư chỉ 0,6131.
- *Về vai trò điều phối của mô hình tổng hợp (Meta-Learner):* Phân tích SHAP và sai số thực tế chứng minh mô hình tổng hợp Meta-Learner (LightGBM) đã thực sự nắm bắt được ngữ cảnh vận hành: tự động ưu tiên kết quả của ElasticNet vào ban đêm khi phụ tải êm dịu, và dồn trọng số cho XGBoost vào ban ngày khi nhu cầu làm mát tăng vọt.

3. Vì sao phương pháp đề xuất lại đạt kết quả vượt trội? Sự thành công của CAS đến từ hai lý do chính:

1. *Đặc trưng phản ánh đúng quy luật thời tiết:* Các sóng điều hòa Fourier giúp mô hình nhận biết chu kỳ các mùa một cách liên tục, tránh hiện tượng nhảy bậc đột ngột giữa các tháng. Chỉ số nhu cầu nhiệt CDD và HDD với ngưỡng cơ sở 18°C phản ánh chính xác mức nhiệt độ kích hoạt người dân bật điều hòa hoặc máy sưởi, giúp mô hình nhận biết sớm các thời điểm phụ tải tăng vọt.
2. *Cơ chế kết hợp linh hoạt theo thời điểm:* Khác với các phương pháp lấy trung bình cố định (*simple averaging*) vốn áp dụng trọng số cào bằng cho mọi thời điểm, mô hình tổng hợp (Meta-Learner) trong kiến trúc CAS được tích hợp trực tiếp các biến ngữ cảnh về thời gian và nhiệt độ môi trường. Nhờ vậy, mô hình tự động điều chỉnh phân bổ trọng số tối ưu: ưu tiên khai thác đặc tính làm mịn của ElasticNet vào ban đêm và tăng cường sức mạnh phi tuyến của XGBoost vào các khung giờ cao điểm nắng nóng để tối ưu độ chính xác.

4. Điểm khác biệt so với bài báo gốc là gì? Bài báo gốc [iise2025pge](#) tiếp cận bài toán bằng cách chia nhỏ thành 24 mô hình XGBoost riêng cho từng giờ. Cách làm này xử lý được sự khác biệt giữa các giờ, nhưng lại vô tình cô lập các giờ với nhau và bỏ qua tính liên tục của thời tiết qua các mùa. Nghiên cứu của chúng tôi chỉ ra rằng mô hình cây bộc lộ điểm yếu khi dự báo ban đêm, và giải pháp tối ưu không phải là cố gắng chỉnh lại tham số của cây, mà là đưa thêm mô hình tuyến tính vào để cùng phối hợp.

Phân tích các trường hợp dự báo sai (Error Analysis)

Khi xem xét kỹ các mốc thời gian có sai số lớn nhất ($|y - \hat{y}| > 350$ MW, gồm 328/8.760 giờ trên tập kiểm thử Năm 3), chúng tôi nhận thấy sai số tập trung rõ nét vào ba hiện tượng vật lý và xã hội thực tế:

- *Hiện tượng tích tụ nhiệt sau nhiều ngày nắng nóng liên tiếp (01/09 – 08/09/2022):* Tháng 9 chiếm tới 117/328 giờ (hơn 35%) có sai số lớn của cả năm. Đỉnh điểm là ngày 06 và 07/09/2022 sau gần một tuần sóng nhiệt lịch sử tại California, phụ tải thực tế đạt đỉnh kỷ lục 4.633 MW (lúc 16:00 ngày 07/09), trong khi mô hình dự báo 3.976 MW (lệch -656 MW); đến 19:00 cùng ngày, phụ tải thực tế vẫn ở mức 4.342 MW so với dự báo

3.505 MW (lệch -836 MW). Đây là minh chứng thực nghiệm của hiện tượng quán tính nhiệt: khi nhiệt lượng tích tụ sâu trong kết cấu công trình đô thị sau nhiều ngày liên tiếp, điều hòa phải vận hành hết công suất ngay cả khi nhiệt độ ngoài trời buổi tối đã hạ nhiệt.

- *Các ngày lễ có lịch nghỉ và hoạt động biến động (Memorial Day và Labor Day):* Vào ngày lễ Memorial Day (30/05/2022, Thứ Hai), phụ tải thực tế trung bình ngày giảm sâu xuống 1.726 MW (thấp hơn đáng kể so với mức trung bình 1.919 MW của các ngày Thứ Hai thông thường trong tháng 5). Mô hình dự báo trung bình 1.968 MW (dự báo thừa +242 MW) do các cơ sở sản xuất và thương mại đóng cửa đồng loạt sâu hơn mức trung bình của ngày cuối tuần. Tương tự, ngày lễ Labor Day (05/09/2022) lại rơi đúng đợt sóng nhiệt, tạo ra sự giằng co giữa việc giảm tải sinh hoạt ngày lễ và tăng tải làm mát khẩn cấp, dẫn đến độ lệch từ -425 MW đến -697 MW ở các giờ cao điểm chiều tối.
- *Các đợt nắng nóng bất thường đầu mùa (tháng 5):* Tháng 5 ghi nhận 34 giờ có sai số lệch trên 350 MW, tập trung vào đợt nắng sớm từ ngày 12 đến 14/05/2022. Vào khung giờ trưa và đầu giờ chiều (12:00 – 15:00), mô hình bị dự báo thừa từ +350 đến +455 MW (ví dụ ngày 12/05 lúc 14:00: thực tế 1.383 MW, dự báo 1.810 MW, chênh +427 MW; ngày 13/05 lúc 15:00: thực tế 1.845 MW, dự báo 2.300 MW, chênh +455 MW). Nguyên nhân là trong đợt nóng đầu tiên của năm, người dân chưa có phản xạ bật điều hòa đồng loạt mà ưu tiên mở cửa hoặc bật quạt, tạo ra độ trễ tâm lý thích nghi so với giữa mùa hè.

Giới hạn và độ tin cậy

Dù đạt kết quả rất khả quan, nghiên cứu vẫn có một số giới hạn cần nhìn nhận khách quan:

- *Phạm vi địa lý và khí hậu:* Nghiên cứu được thực nghiệm trên lưới điện PG&E tại bang California, nơi có khí hậu Địa Trung Hải đặc trưng (mùa hè khô nóng, mùa đông ôn hòa). Ngưỡng nhiệt 18°C và ưu thế của mô hình tuyến tính vào ban đêm có thể sẽ cần điều chỉnh lại nếu áp dụng cho những nơi có khí hậu nhiệt đới ẩm (như Việt Nam) hoặc những vùng có mùa đông băng giá kéo dài.
- *Giả định về dữ liệu thời tiết:* Thí nghiệm hiện đang sử dụng số liệu nhiệt độ thực tế đo đạc tại trạm quan trắc (đúng theo thiết lập của cuộc thi). Trong điều kiện vận hành thực tế ngoài hiện trường, người vận hành phải dùng số liệu thời tiết từ các bản tin dự báo khí tượng vốn luôn có sai số nhất định.
- *Thời gian tính toán:* Việc huấn luyện cùng lúc hai mô hình cơ sở và một mô hình kết hợp khiến thời gian huấn luyện lâu hơn khoảng 1.6 lần so với mô hình đơn lẻ. Tuy nhiên, khi đưa vào sử dụng thực tế để dự báo cho 24 giờ tới, toàn bộ quá trình tính toán chỉ mất chưa đầy 0.15 giây, hoàn toàn đáp ứng tốt yêu cầu vận hành theo chu kỳ ngày của ngành điện.

VII. Kết luận và hướng nghiên cứu tiếp theo

Nghiên cứu này tập trung giải quyết bài toán dự báo phụ tải điện theo giờ cho lưới điện quy mô lớn của công ty PG&E (bang California), xuất phát từ một đặc điểm thực tế: nhu cầu dùng điện vào ban đêm rất ổn định và bằng phẳng, trong khi ban ngày mùa hè lại tăng vọt và biến động phức tạp do nắng nóng. Nhằm giúp mô hình nắm bắt tốt cả hai trạng thái tiêu thụ này, chúng tôi đã bổ sung các đặc trưng gắn liền với quy luật thời tiết (sóng điều hòa Fourier theo mùa cùng chỉ số nhu cầu làm mát và sưởi ấm CDD/HDD), đồng thời xây dựng mô hình học kết hợp linh hoạt (*Context-Aware Stacking* - CAS) để tận dụng thế mạnh bù trừ giữa mô hình hồi quy tuyến tính ElasticNet và mô hình cây XGBoost.

Từ các kết quả thực nghiệm thu được, nghiên cứu rút ra ba kết luận quan trọng:

1. **Mô hình đề xuất đạt độ chính xác vượt trội:** Trên tập dữ liệu kiểm thử độc lập Năm 3 (năm 2022), mô hình CAS đạt sai số RMSE **141.81 MW**, MAPE **4.75%** và hệ số R^2 đạt **0.9136**. Kết quả này giúp cắt giảm tới **29.03 MW** sai số (tương đương mức cải thiện **17.00%**) so với mô hình cơ sở 24-Hourly XGBoost của bài báo gốc **iise2025pge**, đồng thời vượt trội hơn tất cả các mô hình đơn lẻ khác.
2. **Đặc trưng thời tiết và sự kết hợp bù trừ đóng vai trò then chốt:** Việc bổ sung chu kỳ mùa liên tục qua sóng Fourier và chỉ số nhu cầu nhiệt CDD/HDD giúp giảm trực tiếp 10.04 MW sai số. Nghiên cứu cũng chứng minh trên thực tế rằng mô hình tuyến tính ElasticNet dự báo ban đêm tốt hơn hẳn mô hình cây XGBoost (131.33 MW so với 141.37 MW), trong khi XGBoost lại chiếm ưu thế áp đảo khi nhiệt độ tăng cao vào mùa hè (244.16 MW so với 313.27 MW). Hệ số tương quan sai số $r = 0.6131$ khẳng định hai mô hình này là những mảnh ghép bù trừ rất lý tưởng cho nhau.
3. **Mô hình tổng hợp (Meta-Learner) điều phối linh hoạt theo ngữ cảnh:** Phân tích SHAP và sai số theo từng điều kiện khẳng định mô hình tổng hợp Meta-Learner (LightGBM) đã tự động nắm bắt quy luật thực tế: ưu tiên kết quả từ mô hình tuyến tính khi thời tiết ôn hòa hoặc ban đêm, và tăng cường tỷ trọng của mô hình cây khi đối mặt với các đỉnh tải do nắng nóng ban ngày.

Đóng góp thực tế của bài báo:

- *Về mặt giải pháp kỹ thuật:* Đưa ra một cách kết hợp thông minh giữa mô hình tuyến tính đơn giản và mô hình cây phi tuyến, chứng minh rằng không cần phải áp dụng các mạng học sâu (Deep Learning) cồng kềnh mà vẫn có thể nâng cao độ chính xác dự báo một cách rõ rệt.
- *Về mặt vận hành hệ thống điện:* Mức cải thiện 17.00% sai số RMSE có ý nghĩa kinh tế trực tiếp: giúp các kỹ sư điều độ dự báo sát nhu cầu dùng điện thực tế, từ đó cắt giảm chi phí duy trì các tổ máy phát điện dự phòng, hạn chế lãng phí năng lượng và chủ động ứng phó với các đợt cao điểm nắng nóng.

Giới hạn của nghiên cứu: Kết quả nghiên cứu hiện được kiểm chứng trên tập dữ liệu của khu vực Bắc California (khí hậu Địa Trung Hải ôn hòa) và dựa trên số liệu thời tiết quan trắc thực tế đo tại trạm, chưa tính đến sai số của các bản tin dự báo khí tượng thời gian thực.

Hướng nghiên cứu tiếp theo: Để tiếp tục hoàn thiện mô hình và phục vụ tốt hơn cho công tác vận hành ngoài thực tế, các hướng phát triển tiếp theo nên tập trung vào:

1. *Đánh giá tác động của sai số dự báo thời tiết:* Thử nghiệm mô hình với các dữ liệu dự báo khí tượng mô phỏng (NWP) có chứa sai số nhằm kiểm tra mức độ ảnh hưởng đến kết quả khi triển khai thực tế.
2. *Kiểm nghiệm trên các vùng khí hậu khác biệt:* Áp dụng quy trình CAS cho các hệ thống điện có đặc thù thời tiết khác, ví dụ như lưới điện Texas (nhiệt đới ẩm, nhu cầu điều hòa rất lớn) hay các bang phía Bắc có mùa đông tuyết giá kéo dài, đồng thời tối ưu lại ngưỡng nhiệt cơ sở của chỉ số nhu cầu nhiệt CDD/HDD cho phù hợp với tập quán sinh hoạt của từng địa phương.
3. *Dự báo khoảng tin cậy thay vì chỉ dự báo một con số điểm:* Tích hợp thêm các kỹ thuật ước lượng độ bất định (như *Conformal Prediction* hoặc hồi quy phân vị) vào mô hình Stacking, nhằm cung cấp khoảng dao động tải tin cậy cho người điều độ, giúp nâng cao tính an toàn trong quản lý lưới điện.

VIII. Tài liệu tham khảo

Phụ lục